

Contents

1. Hadamard Rotation: 定义与计算不变性
2. 为什么引入 Rotation: Memory Wall 与 Outliers
3. 硬件映射: FWHT 蝶形网络
4. 从全局旋转到局部旋转
5. Non-PoT 维度与 Kronecker 分解

Source: ISSCC RotationQuant slides

Hadamard Rotation: 定义与计算不变性

- 正交性:

$$Q Q^T = I$$

rotation 保持 L2 norm, 不改变向量能量。


- 自逆性:

$$H^{-1} = H$$

Hadamard 矩阵正交且对称, 逆变换开销低。

- 线性计算不变性:


$$A W^T = (A H)(H^T W^T)$$



旋转矩阵可插入 activation 与 weight 之间, 并在离线阶段吸收到权重中。

为什么需要 Rotation: Memory Wall 与 Outliers

- **Memory Wall:** 自回归解码阶段需要反复读取权重，访存带宽成为主要瓶颈。
- **低位宽量化:** W4A4 / W4A8 可降低带宽压力，但对数值分布更敏感。
- **Activation Outliers:** 少量极大值会主导量化 scale，使多数正常值分辨率下降。
- **Outlier-Free:** Hadamard rotation 将集中能量打散到各维度，使分布更平滑。



硬件映射：FWHT 蝶形网络


- 复杂度：

$$O(N^2) \rightarrow O(N \log_2 N)$$

避免完整矩阵乘法。


- 数据路径：核心由加法、减法和 routing / MUX 构成。
- PPA 收益：较短关键路径与较低门级复杂度，有利于吞吐率和功耗。

FWHT-Based Rotation



从全局旋转到局部旋转

- **全局旋转的问题**：通道维度很大时，完整 FWHT 网络深度和面积仍可能过高。
- **Subspace / Local Rotation**：在较小子空间内执行旋转，配合 group quantization 降低硬件映射成本。
- **设计目标**：在保持 outlier smoothing 效果的同时，控制面积、routing 和时序压力。




Non-PoT 维度与 Kronecker 分解

- LLM 通道维度不总是 2 的幂，直接构造大 Hadamard 变换不总是匹配。
- Kronecker 分解：

$$H_{Ch} = H_N \otimes H_M$$

将大维度旋转拆成可映射的小 FHT 单元与小矩阵乘法单元。

- Takeaways:
 - 数值上保持计算等价；
 - 分布上削弱 outliers；
 - 硬件上更容易做局部化映射。



Rotation 的价值在于同时连接数值分布、量化位宽和硬件数据路径。